

APRENDIZAJE NO SUPERVISADO

Descubrir estructura cuando no hay respuestas

BLOQUE 0 · ENFOQUE GENERAL DE LA SESIÓN (nuevo y clave)

Qué vas a hacer realmente en esta sesión

Hasta ahora, en el curso, siempre ha ocurrido algo parecido:

- había una variable objetivo
- entrenabas un modelo
- medías si funcionaba o no

En esta sesión **eso desaparece**.

Aquí vas a trabajar con datos donde:

- no hay etiquetas,
- no hay "respuesta correcta",
- y aun así **tienes que tomar decisiones**.

Concretamente, aprenderás a:

- agrupar datos sin saber cuántos grupos existen,
- detectar cuándo un resultado **no tiene sentido**,
- entender por qué cambiar una decisión (escala, métrica, modelo)
cambia completamente lo que ves.

No se trata de "aprender K-Means".

Se trata de **aprender a pensar cuando no hay guía externa**.

Qué NO es esta sesión (para evitar confusión)

- No es una sesión de trucos de `sklearn`
- No es una sesión de "ejecuta esto y ya"
- No es una sesión donde el modelo decide por ti

Es una sesión donde:

tú eres parte del modelo,
porque interpretas y decides.

Desde el punto de vista del modelador

En esta sesión empiezas a hacer algo nuevo:

Dejas de preguntar "¿predice bien?"
y empiezas a preguntar "¿esto tiene sentido?"

Ese cambio de pregunta es el verdadero aprendizaje.

BLOQUE 1 · APRENDER SIN RESPUESTAS CORRECTAS

Qué cambia cuando desaparece la variable objetivo

1.1 Conexión con lo que ya sabes (anclaje explícito)

Hasta ahora, en todas las sesiones anteriores del curso, has trabajado siempre bajo el mismo esquema mental, aunque los modelos fueran distintos:

- En la **Sesión 3**, visualizabas datos para entender distribuciones.
- En la **Sesión 4**, usabas gráficas para anticipar problemas de modelado.
- En la **Sesión 5**, construías modelos con una función objetivo clara.
- En la **Sesión 6**, evaluabas modelos comparando predicción y valor real.

En **todos los casos**, había algo en común:

Existía una referencia externa que te decía si el modelo iba bien o mal.

Esa referencia era:

- una etiqueta,
- una variable objetivo,
- una medida de error asociada a ella.

En esta sesión, **eso desaparece**.

Este bloque existe para que entiendas **qué implica exactamente perder esa referencia**

antes de que empieces a usar ningún modelo nuevo.

1.2 El cambio fundamental: ya no hay "respuesta correcta"

En aprendizaje supervisado, el proceso es claro:

1. El modelo hace una predicción.
2. Esa predicción se compara con un valor real.
3. Se calcula un error.
4. El error guía las decisiones.

Este mecanismo te permite responder preguntas como:

- "¿este modelo es mejor que el anterior?"
- "¿he mejorado tras cambiar un parámetro?"

En aprendizaje no supervisado **ninguna de estas preguntas tiene sentido**.

Aquí:

- no hay etiquetas,
- no hay valores reales,

- no hay error en el sentido clásico.

Esto no es una limitación técnica.

Es una **característica estructural del problema**.

El modelo no puede "acertar" o "fallar",
porque no existe una verdad externa contra la que comparar.

Ancla analógica · Ordenar sin etiquetas (para bajar ansiedad)

Imagina que te dan una biblioteca de libros antiguos sin ninguna etiqueta.

En aprendizaje supervisado, un bibliotecario te entrega categorías claras ("Novela", "Historia", "Ciencia") y tu trabajo consiste en aprender a reconocerlas.

En aprendizaje no supervisado, nadie te da esas etiquetas.

Tienes que agrupar tú los libros:

- por tamaño,
- por color,
- por tipo de papel,
- o por temática estimada.

Ninguna de estas agrupaciones es "incorrecta" por definición. Pero no todas **sirven para lo mismo**:

- agrupar por tamaño puede optimizar el espacio,
- agrupar por temática puede ayudarte a encontrar ideas.

En clustering ocurre exactamente lo mismo:

el modelo propone una organización,
tú decides si **sirve para tu objetivo**.

1.3 Entonces, ¿qué significa "aprender" en este contexto?

Este es el primer concepto nuevo importante de la sesión y conviene fijarlo bien.

En aprendizaje no supervisado, *aprender* no significa:

- aproximar una función objetivo,
- minimizar un error respecto a una salida conocida.

Aprender significa:

| descubrir estructura interna en los datos.

Esa estructura puede tomar muchas formas:

- observaciones que se parecen entre sí,
- regiones densas del espacio,
- patrones repetidos,
- comportamientos atípicos.

Este tipo de aprendizaje **no responde directamente a una pregunta**,

sino que **organiza la información disponible** para que puedas formular mejores preguntas después.

👉 Esta idea conecta directamente con lo que hiciste en la **Sesión 4**, cuando usabas visualizaciones no para predecir, sino para *pensar antes de modelar*.

1.4 Por qué esto no es “exploración sin importancia”

Es habitual pensar que el aprendizaje no supervisado sirve solo para:

- “echar un vistazo a los datos”,
- “hacer un análisis previo”,
- “preparar el dataset”.

Esa visión es incompleta y peligrosa.

Hay muchos problemas reales donde:

- no existen etiquetas,
- definirlas es imposible,
- o hacerlo no tendría sentido.

Ejemplos típicos:

- segmentación de clientes sin categorías previas,
- análisis de logs desconocidos,
- detección de comportamientos anómalos,
- exploración inicial de datos científicos.

En estos casos:

El aprendizaje no supervisado no es una fase previa,
es **el modelo principal**.

Si quieres profundizar en **qué tipos de problemas se consideran no supervisados**, consulta la introducción oficial de scikit-learn sobre aprendizaje no supervisado.

Ahí verás claramente **qué preguntas sí y cuáles no puede responder este enfoque**.

1.5 Tu nuevo papel como modelador (concepto clave)

Este bloque introduce un cambio importante en tu rol.

Hasta ahora, como modelador:

- entrenabas un modelo,
- calculabas una métrica,
- tomabas decisiones en función de ese número.

A partir de ahora:

- el modelo **propone** una estructura,
- tú **la interpretas**,
- y decides si tiene sentido o no en el contexto del problema.

Esto significa que:

- el modelo ya no valida el resultado,

- la validación pasa a ser **conceptual y contextual**.

Este rol más activo no es una debilidad del enfoque,
es lo que lo hace potente.

👉 Esta idea será **crítica** en el bloque 6, cuando veamos cómo evaluar clustering sin etiquetas.

1.6 Error típico que debes evitar desde el principio

Un error muy común al empezar con aprendizaje no supervisado es este:

Intentar forzar una evaluación automática
como si fuera un problema supervisado.

Esto suele manifestarse como:

- buscar una "accuracy encubierta",
- confiar ciegamente en una métrica sin interpretación,
- asumir que un número alto implica un buen resultado.

El síntoma típico es:

aceptar un resultado porque "el score es bueno",
aunque no tenga sentido al observar los datos.

Este error aparece cuando no se acepta el cambio de paradigma que introduce este bloque.

1.7 Qué deberías tener claro al cerrar este bloque

Antes de pasar al siguiente bloque, deberías poder afirmar lo siguiente:

- Entiendo por qué aquí no hay etiquetas.
- Sé que el modelo no puede decirme si algo es correcto.
- Acepto que interpretar resultados forma parte del trabajo.
- Entiendo que el objetivo es **descubrir estructura**, no predecir.

Si esto no está claro, **el resto de la sesión no funcionará.**

1.8 Puente explícito hacia el siguiente bloque

En el siguiente bloque vamos a dar el primer paso operativo real:

| Dejar de ver los datos como una tabla
| y empezar a verlos como **puntos en un espacio.**

Ahí reaparecerán conceptos que ya conoces:

- visualización,
- escalado,
- relaciones entre variables,

pero ahora con un propósito distinto:

| tomar decisiones sin una referencia externa.

Referencias activadas en este bloque

- scikit-learn — *Unsupervised learning overview*
👉 Úsala para identificar **qué tipos de problemas** se consideran no supervisados y por qué.
 - Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, Capítulo 14
👉 Para entender el marco teórico completo del aprendizaje no supervisado.
 - Géron — *Hands-On Machine Learning*, capítulo de aprendizaje no supervisado
👉 Para ver cómo este cambio de paradigma se refleja en flujos de trabajo reales.
-

BLOQUE 2 · EL ESPACIO DE CARACTERÍSTICAS COMO OBJETO DE DECISIÓN

De “tabla de datos” a “geometría sobre la que actúas”

2.1 Conexión con lo que ya sabes (anclaje explícito)

Antes de esta sesión, ya has trabajado varias veces con la idea de que:

- cada fila representa una observación,
- cada columna representa una variable,
- los datos pueden visualizarse para entender relaciones.

En concreto:

- En la **Sesión 3**, visualizaste variables para entender distribuciones.
- En la **Sesión 4**, empezaste a pensar en los datos como *nubes de puntos* al visualizar relaciones entre variables.
- En la **Sesión 5**, esas variables se convirtieron en *entradas de un modelo*.
- En la **Sesión 6**, evaluaste cómo esas entradas afectaban al rendimiento.

Hasta ahora, sin embargo, todo eso tenía un propósito claro:

| predecir una variable objetivo.

En esta sesión, las variables **ya no son “entradas” de una función**, sino **coordenadas de un espacio** que vas a analizar y modificar.

Este bloque existe para que entiendas **qué implica exactamente ese cambio**.

2.2 El dataset deja de ser una tabla

En aprendizaje no supervisado, el dataset ya no se interpreta principalmente como:

- una estructura tabular,

- un conjunto de columnas independientes,
- una colección de valores a procesar.

Conceptualmente, el dataset pasa a ser:

| una nube de puntos en un espacio de características.

Esto significa que:

- cada observación es un punto,
- cada variable es una dimensión,
- la posición relativa entre puntos **es lo que importa**.

Esta idea no es nueva —ya la has rozado al visualizar datos—
pero aquí se vuelve **central**.

👉 En el bloque 4 (clustering), esta nube de puntos será el objeto directo del modelo.

2.3 Qué significa “espacio de características”

Introducimos aquí un concepto que usaremos **en todos los bloques siguientes**:

| Espacio de características:
el espacio matemático definido por las variables del dataset,
donde cada observación ocupa una posición concreta.

Algunas consecuencias importantes:

- Si tienes 2 variables → espacio bidimensional.
- Si tienes 3 variables → espacio tridimensional.
- Con más variables → espacios de alta dimensión (no visualizables, pero analizables).

En aprendizaje no supervisado:

| el modelo actúa sobre este espacio,
no sobre columnas aisladas.

Por eso, cualquier decisión que tomes sobre las variables:

- cambia el espacio,
 - cambia las relaciones,
 - cambia el resultado final.
-

2.4 Primera decisión real: qué variables definen el espacio

Aquí aparece **la primera decisión explícita del modelador** en esta sesión:

| ¿Qué variables definen el espacio sobre el que voy a trabajar?

Incluir una variable implica:

- añadir una dimensión,
- alterar distancias,
- modificar la geometría global.

Excluir una variable implica:

- eliminar una fuente de variación,
- simplificar el espacio,
- perder (o eliminar) información.

No hay una respuesta universal correcta.

👉 Esta misma decisión ya existía en sesiones anteriores, pero ahora **sus consecuencias son mucho más visibles**, porque no hay variable objetivo que “compense” una mala elección.

2.5 La escala deja de ser un detalle técnico

En sesiones anteriores, el escalado de variables podía parecer:

- una buena práctica,
- una recomendación,

- algo que "conviene hacer".

En aprendizaje no supervisado, el escalado es:

| una decisión estructural sobre el espacio.

Si una variable tiene un rango mucho mayor que otra:

- domina las distancias,
- distorsiona la geometría,
- impone su peso al modelo.

El efecto típico de una mala escala es este:

| el modelo agrupa datos según una sola variable,
| aunque tú no lo pretendieras.

Este fenómeno **no es un bug**, es una consecuencia directa del espacio que has definido.

👉 En el bloque 3, cuando hablemos de distancia, verás por qué ocurre esto.

Si quieres revisar **qué técnicas de escalado existen y cuándo se usan**, consulta la sección de preprocesado de scikit-learn, pero hazlo con esta pregunta en mente:

"¿Qué geometría estoy imponiendo a mis datos?"

Ejemplo intuitivo · Cuando una variable se come a las demás

Supón dos variables:

- Ingresos anuales: de 0 a 100.000 €
- Número de hijos: de 0 a 5

Si usas una distancia euclídea sin escalar, una diferencia de 10.000 € domina completamente la geometría del espacio.

El modelo puede considerar **"muy parecidas"** dos personas con 0 y 3 hijos **si ganan lo mismo**, porque la distancia está gobernada casi por completo por el dinero.

El modelo no está “mintiendo”. Está siendo coherente con el espacio que tú has definido.

2.6 El error típico: pensar que el espacio “es neutro”

Uno de los errores más comunes al empezar con no supervisado es asumir que:

| “Los datos ya están como están; el algoritmo hará el resto.”

Esto es falso.

En realidad:

- **tú defines el espacio,**
- el algoritmo solo opera dentro de él.

Síntomas típicos de este error:

- clusters extraños o triviales,
- resultados muy sensibles a pequeños cambios,
- interpretaciones que no encajan con el dominio.

Cuando eso ocurre, el problema **no suele ser el algoritmo,** sino el espacio sobre el que se le ha pedido trabajar.

2.7 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave son:

- qué variables entran en el espacio,
- cómo están escaladas,
- qué significado tiene la cercanía entre puntos.

Una buena práctica en este punto no es:

| “probar algoritmos distintos”,

sino:

observar cómo cambia el espacio
cuando cambias una sola decisión.

Esta forma de pensar será esencial en:

- clustering (bloques 4 y 5),
- evaluación (bloque 6),
- reducción de dimensionalidad (bloque 8).

2.8 Puente explícito hacia el siguiente bloque

En el siguiente bloque vamos a formalizar una idea que ya ha aparecido varias veces aquí:

qué significa que dos puntos estén “cerca”.

Ahí verás que:

- la distancia no es única,
- distintas métricas producen estructuras distintas,
- y que elegir una distancia es **elegir una interpretación del espacio**.

Todo lo que has leído en este bloque es el **prerrequisito directo** para entenderlo.

Referencias activadas en este bloque

- scikit-learn — *Preprocessing and scaling*
👉 Para revisar **cómo distintas técnicas de escalado alteran el espacio de características**.
- Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, secciones sobre feature space
👉 Para profundizar en la visión geométrica del aprendizaje automático.
- Bishop — *Pattern Recognition and Machine Learning*, capítulos iniciales
👉 Para entender el espacio de características como objeto matemático.

Este bloque **no introduce nada que no vayas a usar inmediatamente**

Todo reaparece, explícitamente, en los bloques 3 y 4.

Ahora que ya has visto el fenómeno con un ejemplo humano (Ingresos vs Hijos), vamos a observarlo en datos con un escalado estándar: la idea es comprobar cómo cambian los rangos y, por tanto, la geometría del espacio.

► Ejemplo mínimo reproducible · Escalar cambia el espacio

```
import pandas as pd
from sklearn.preprocessing import StandardScaler

df = pd.read_csv("session7_base.csv")
X = df[["feature1", "feature2", "feature3"]].to_numpy()

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print("Rango original:", X.min(axis=0), X.max(axis=0))
print("Media escalada:", X_scaled.mean(axis=0))
print("Desviación escalada:", X_scaled.std(axis=0))
```

► Si algo no cuadra, revisa...

- ¿Alguna variable domina claramente el rango?
- ¿Tiene sentido comparar distancias sin escalar en este dominio?

BLOQUE 3 · DISTANCIAS Y SIMILITUD

Decidir qué significa que dos observaciones se parezcan

3.1 Conexión con lo que ya sabes (anclaje explícito)

En el bloque anterior has aceptado una idea clave:

| El dataset ya no es una tabla,

| es una **nube de puntos en un espacio de características**.

Eso implica algo inmediato, aunque todavía no lo hayamos nombrado:

- los puntos están más o menos cerca unos de otros,
- esa cercanía **importa**,
- y el modelo va a basarse en ella.

Hasta ahora, en sesiones anteriores:

- en la **Sesión 3**, comparabas visualmente puntos en una gráfica,
- en la **Sesión 4**, intuías agrupaciones al ver distribuciones,
- en la **Sesión 5**, el modelo aprendía pesos que implícitamente definían cercanía,
- en la **Sesión 6**, evaluabas resultados sin pensar en geometría explícita.

En aprendizaje no supervisado, esa geometría deja de ser implícita.

Este bloque existe para responder de forma explícita a una pregunta inevitable:

| ¿Qué significa exactamente que dos observaciones estén “cerca”?

3.2 La idea clave: el modelo no ve datos, ve relaciones

Este es uno de los puntos más importantes de toda la sesión.

En aprendizaje no supervisado:

- el modelo **no interpreta valores individuales**,
- no entiende el significado semántico de las variables,
- no sabe qué es “edad”, “precio” o “tiempo”.

Lo único que puede hacer es:

| comparar observaciones entre sí.

Y esa comparación se hace mediante una noción de:

- cercanía,

- distancia,
- similitud.

Por tanto:

| elegir una distancia es decidir cómo se comparan los datos.

Nada más y nada menos.

3.3 Qué es una distancia (conceptualmente, no matemáticamente)

Una distancia es una función que, dadas dos observaciones:

- devuelve un número,
- que representa cuán distintas son,
- según un criterio concreto.

Ese criterio **no es neutral**.

Define:

- qué diferencias importan,
- cuáles se ignoran,
- cómo se combinan las variaciones de las distintas variables.

En aprendizaje no supervisado:

| la distancia es el lenguaje básico del modelo.

Todo lo que venga después (clustering, densidad, reducción de dimensionalidad) se apoya directamente en esta decisión.

3.4 Distancia euclídea: la intuición más común (y sus supuestos)

La distancia más habitual es la **distancia euclídea**, que coincide con la intuición geométrica de:

“distancia en línea recta”.

Es la que probablemente estás imaginando si piensas en puntos en un plano.

Usarla implica aceptar varios supuestos, aunque no siempre se mencionen:

- todas las variables contribuyen de forma comparable,
- el espacio es homogéneo,
- la cercanía “en línea recta” tiene sentido,
- los clusters (si existen) tienden a ser compactos.

Por eso:

- es la base de algoritmos como K-Means,
- funciona bien en muchos casos sencillos,
- pero **no es universal**.

👉 En el bloque 5 verás cómo estas suposiciones condicionan completamente el resultado de K-Means.

3.5 Otras nociones de distancia: cambiar la interpretación del espacio

Existen otras formas de medir cercanía, como la distancia Manhattan, que:

- suma diferencias dimensión a dimensión,
- penaliza los cambios de otra manera,
- produce una geometría distinta del espacio.

La idea importante **no es memorizar distancias**, sino entender esto:

Cambiar la distancia

es cambiar **la forma del espacio**

y, por tanto, **la estructura que el modelo puede descubrir**.

Dos observaciones que parecen “muy cercanas” con una distancia:

- pueden no serlo con otra.

Esto no es una contradicción:

| son interpretaciones distintas del mismo dataset.

3.6 La distancia nunca actúa sola: conexión con el escalado

Aquí volvemos explícitamente a algo que ya viste en el bloque 2.

La distancia siempre actúa sobre:

- el espacio que has definido,
- con las variables que has elegido,
- y con la escala que les has dado.

Por eso:

- una mala escala distorsiona la distancia,
- una variable dominante “arrastra” el resultado,
- el modelo parece descubrir patrones que en realidad has impuesto tú.

Este es uno de los errores más frecuentes en no supervisado.

👉 Si este punto no está claro, vuelve al bloque 2 antes de seguir avanzando.

3.7 Error típico: tratar la distancia como un detalle técnico

Un error muy común es pensar:

| “La distancia es algo interno del algoritmo;
| yo solo tengo que ejecutar el modelo.”

Esto lleva a situaciones como:

- clustering incoherente,
- resultados extremadamente sensibles,
- interpretaciones que no encajan con el dominio.

El síntoma típico es:

cambiar de algoritmo esperando que “funcione mejor”,
cuando el problema es **cómo se está midiendo la similitud**.

3.8 Desde el punto de vista del modelador (capa de decisión)

En este bloque, la decisión clave es:

Qué significa “parecido” en mi problema concreto.

Antes de ejecutar cualquier algoritmo, deberías ser capaz de preguntarte:

- ¿qué variables deberían pesar más?
- ¿qué tipo de diferencias quiero destacar?
- ¿qué diferencias quiero ignorar?

No responder explícitamente a estas preguntas
equivale a dejar que el algoritmo decida por ti.

Y en no supervisado, eso suele acabar mal.

3.9 Puente explícito hacia el siguiente bloque

En el siguiente bloque todo lo que has leído aquí se materializa por primera vez en un modelo concreto:

el clustering.

Ahí verás que:

- los grupos se forman **solo a partir de distancias**,
- no hay ninguna otra fuente de información,
- y que cambiar la noción de similitud
cambia radicalmente el resultado.

Si entiendes bien este bloque,
el clustering **no te parecerá magia**.

Referencias activadas en este bloque

- scikit-learn — *Distance metrics*
👉 Úsala para ver **qué métricas existen y qué tipo de problemas suelen modelar**.
 - Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, secciones de clustering
👉 Para entender cómo la distancia afecta a la estructura descubierta.
 - Bishop — *Pattern Recognition and Machine Learning*, capítulos sobre métricas
👉 Para profundizar en la relación entre distancia y representación.
-

Este bloque **cierra el marco conceptual básico** del aprendizaje no supervisado.

A partir de aquí, todo lo que ocurra será consecuencia directa de:

- el espacio que has definido,
 - y la distancia que has elegido.
-

BLOQUE 4 · CLUSTERING

Agrupar sin saber cuántos grupos hay (ni si existen)

4.1 Conexión con lo que ya sabes (anclaje explícito)

En los bloques anteriores has construido, paso a paso, el marco necesario:

- En el bloque **1**, aceptaste que no hay respuesta correcta.
- En el bloque **2**, entendiste que los datos forman un espacio.
- En el bloque **3**, decidiste cómo medir cercanía dentro de ese espacio.

Si juntas esas tres ideas, aparece una consecuencia inevitable:

Si tengo puntos en un espacio
y sé medir qué puntos están cerca,
puedo intentar agruparlos.

Eso es exactamente lo que hace el clustering.

Este bloque existe para responder a esta pregunta concreta:

¿Qué significa “formar grupos” cuando nadie me dice cuáles existen?

4.2 Qué es realmente el clustering (definición operativa)

De forma precisa, el clustering es:

un conjunto de técnicas cuyo objetivo es
proponer una partición del espacio de datos
tal que los puntos dentro de un grupo sean más similares entre sí
que respecto a los puntos de otros grupos.

Hay tres palabras clave aquí que conviene fijar:

- **proponer** → no descubrir una verdad absoluta
- **partición** → una forma concreta de organizar el espacio
- **similares** → según la distancia que tú hayas definido (bloque 3)

El clustering **no descubre categorías reales.**

Descubre **estructuras coherentes con tus decisiones previas.**

4.3 Qué NO es el clustering (para evitar errores graves)

Antes de seguir, conviene eliminar tres ideas erróneas muy comunes:

1. ❌ *"El clustering descubre las clases reales"*
→ No hay clases reales si no hay etiquetas.
2. ❌ *"Si el resultado es raro, el algoritmo falla"*
→ Normalmente, el problema está en el espacio o la distancia.
3. ❌ *"Siempre hay un número correcto de clusters"*
→ El número de clusters es una **decisión de modelado**, no un dato oculto.

Estas confusiones aparecen cuando se intenta usar clustering como si fuera clasificación sin etiquetas.

4.4 Qué significa "pertenecer a un grupo"

En aprendizaje supervisado:

- una observación **pertenece** a una clase
- esa pertenencia viene dada desde fuera

En clustering:

- una observación es **asignada** a un grupo
- esa asignación depende de:
 - la distancia,
 - el espacio,
 - el criterio del modelo

Esto implica algo importante:

- Un punto no es de un cluster.
- Un punto **acaba en un cluster** bajo ciertas condiciones.

Si cambias esas condiciones, el grupo cambia.

Esto no es un fallo del método.

Es su naturaleza.

4.5 Qué tipo de preguntas responde el clustering

El clustering **no responde** a preguntas como:

- "¿esto está bien o mal?"
- "¿qué etiqueta tiene este punto?"

Responde a preguntas como:

- ¿parecen existir grupos diferenciados?
- ¿qué observaciones se comportan de forma similar?
- ¿hay subestructuras internas en los datos?
- ¿existen patrones repetidos?

Por eso se usa habitualmente para:

- exploración de datos,
- segmentación,
- análisis previo,
- generación de hipótesis.

👉 Esta función es muy parecida a lo que hacías en la **Sesión 4**, pero ahora formalizada en un modelo.

4.6 Primera gran decisión: ¿cuántos grupos?

Aquí aparece una decisión nueva y crítica:

| ¿Cuántos clusters quiero que el modelo proponga?

Y aquí es importante entender algo desde el principio:

- el número de clusters **no suele venir dado**,
- no hay una respuesta "correcta" universal,
- elegir K es elegir un nivel de abstracción.

Pocos clusters:

- visión global,
- poca granularidad.

Muchos clusters:

- más detalle,
- más fragmentación.

👉 En el bloque 6 veremos cómo razonar esta decisión, pero es importante asumir ya que **no es automática**.

4.7 Error típico: confiar demasiado rápido en el resultado

Uno de los errores más habituales cuando se empieza con clustering es este:

“El algoritmo ya ha agrupado los datos,
así que los grupos deben tener sentido.”

El síntoma típico es:

- aceptar clusters sin analizarlos,
- no revisar su composición,
- no cuestionar su coherencia.

En clustering:

el resultado no se valida solo.

Siempre exige interpretación.

4.8 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave que empiezan a aparecer son:

- aceptar que el modelo **propone**, no decide,
- entender que los grupos dependen del espacio y la distancia,

- asumir que el número de clusters es una elección,
- prepararse para **evaluar sin etiquetas**.

Si estas decisiones no se hacen explícitas,
el clustering se convierte en una herramienta peligrosa.

4.9 Puente explícito hacia el siguiente bloque

En el siguiente bloque entraremos por fin en un algoritmo concreto:

| K-Means.

Pero lo haremos con una condición clara:

- no como una receta,
- no como “el clustering”,
- sino como **una interpretación muy concreta** de todo lo que has visto aquí.

Si este bloque está claro,

K-Means no te parecerá arbitrario.

Referencias activadas en este bloque

- scikit-learn — *Clustering overview*
👉 Úsala para ver **qué tipos de clustering existen y qué supuestos hacen**.
 - Jain, A. K. — *Data clustering: 50 years beyond K-means*
👉 Para entender por qué no existe un único enfoque correcto.
 - Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, Cap. 14
👉 Para el marco teórico completo del clustering.
-

Este bloque **cierra el marco general del clustering**.

A partir de aquí, cada algoritmo será una **decisión con consecuencias claras**, no una caja negra.

BLOQUE 5 · K-MEANS

Qué asume realmente este modelo y por qué a veces falla

5.1 Conexión con lo que ya sabes (anclaje explícito)

Antes de entrar en K-Means, recapitulemos **exactamente** qué decisiones ya has tomado:

- En el bloque 2, definiste un **espacio de características**.
- En el bloque 3, decidiste **cómo medir cercanía** (distancia).
- En el bloque 4, aceptaste que el clustering **propone grupos**, no descubre verdades.

K-Means **no añade ninguna idea nueva** a este marco.

Lo que hace es **fijar una forma concreta de interpretar todo lo anterior**.

Este bloque existe para responder a una pregunta muy concreta:

| ¿Qué tipo de estructura supone K-Means que tienen mis datos?

5.2 La idea central de K-Means (sin código, sin fórmulas)

K-Means parte de una hipótesis muy simple y muy fuerte:

| Cada grupo puede representarse por un centro
y cada observación pertenece al grupo
cuyo centro está más cerca.

Ese centro se llama **centroide** y se calcula como:

- el promedio de las observaciones del grupo.

El algoritmo repite dos pasos básicos:

1. asignar cada punto al centroide más cercano,
2. recalcular los centroides con esas asignaciones.

Este proceso se repite hasta que:

- las asignaciones dejan de cambiar,
- o los cambios son mínimos.

Nada más.

Todo lo que hace K-Means se reduce a esta idea.

Intuición geométrica · Cada centroide define un territorio

Puedes imaginar cada centroide como un imán.

El espacio se divide en regiones tales que:

▮ cada punto pertenece al centroide más cercano.



Esta división del espacio en "provincias" se conoce como **diagrama de Voronoi**.

K-Means no solo calcula centros:

▮ divide el espacio en territorios de influencia
▮ según la cercanía a cada centroide.

Por eso asume implícitamente grupos compactos y "redondos".

No necesitas estudiar Voronoi aquí: solo úsalo como imagen mental de cómo K-Means reparte el espacio.



5.3 Qué optimiza realmente K-Means (y por qué importa)

K-Means no “busca grupos” en abstracto.

Optimiza un criterio muy concreto:

| minimizar la distancia de los puntos a su centroide.

Esto tiene consecuencias inmediatas:

- favorece grupos **compactos**,
- penaliza grupos dispersos,
- ignora completamente la forma real del grupo si no se ajusta a esa compacidad.

Por eso:

| K-Means no descubre cualquier estructura,
| descubre estructuras **compatibles con su criterio**.

5.4 Suposiciones implícitas (aquí empiezan los problemas)

Usar K-Means implica aceptar **todas** estas suposiciones, aunque no las declares:

- los clusters son aproximadamente:
 - esféricos,
 - de tamaño similar,
- la distancia euclídea tiene sentido,
- la media representa bien a un grupo,
- no hay outliers dominantes.

Si estas suposiciones **no se cumplen**, el algoritmo:

- no “falla”,

- simplemente **fuerza los datos** a encajar en su modelo.

Este es uno de los puntos más importantes del bloque.

5.5 El parámetro K no es técnico, es conceptual

K-Means exige que decidas **K**, el número de clusters.

Esto **no es un detalle de implementación**.

Elegir K significa:

- decidir cuántas estructuras quieres ver,
- fijar el nivel de abstracción,
- aceptar una forma concreta de resumir los datos.

No existe un K “verdadero” en general.

👉 En el bloque 6 veremos cómo **razonar** esta decisión, pero aquí es clave asumir que **no la decide el algoritmo**.

5.6 Sensibilidad crítica: escala e inicialización

Dos aspectos prácticos de K-Means tienen consecuencias conceptuales directas:

Escala

Si una variable tiene un rango mucho mayor que otras:

- domina la distancia,
- arrastra los centroides,
- define los clusters casi por sí sola.

Síntoma típico:

| los clusters parecen organizados según una única variable.

Esto conecta directamente con el bloque 2.

Si ocurre, el problema no es K-Means: **es el espacio**.

Inicialización

K-Means empieza con centroides iniciales.

Distintas inicializaciones pueden llevar a:

- soluciones distintas,
- mínimos locales,
- resultados inestables.

Síntoma típico:

ejecutas el mismo modelo varias veces
y obtienes agrupaciones diferentes.

Esto no es un bug:

es una consecuencia directa de la optimización que realiza.

5.7 Error típico: usar K-Means como “primer intento automático”

Uno de los errores más comunes es este:

“No sé qué hacer, pruebo K-Means a ver qué sale.”

El problema de este enfoque es que:

- K-Means **siempre devuelve algo**,
- aunque los datos no cumplan sus supuestos,
- y el resultado puede parecer razonable... sin serlo.

Síntoma típico:

- clusters que no se interpretan bien,
 - grupos que no encajan con el dominio,
 - cambios drásticos al tocar un parámetro menor.
-

5.8 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave son:

- aceptar o no las suposiciones de K-Means,
- decidir conscientemente el valor de K,
- comprobar la estabilidad del resultado,
- cuestionar siempre la interpretación.

Una buena práctica aquí no es:

| “probar otro K hasta que quede bonito”,

sino:

| preguntarte si K-Means es el modelo adecuado
| para la estructura que sospechas en tus datos.

5.9 Puente explícito hacia el siguiente bloque

Tras usar K-Means aparece una pregunta inevitable:

| “¿Cómo sé si este clustering es razonable
| si no hay etiquetas?”

Esa pregunta **no es un problema**, es el siguiente paso lógico.

Eso es exactamente lo que abordaremos en el **bloque 6**:

| evaluar clustering sin verdad externa.

Si este bloque está claro,

la evaluación no te parecerá un artificio.

Referencias activadas en este bloque

- scikit-learn — *K-Means clustering*

👉 Úsala para ver **qué optimiza exactamente K-Means y qué parámetros lo controlan.**

- Jain, A. K. — *Data clustering: 50 years beyond K-means*

👉 Para entender por qué K-Means no es un estándar universal.

- Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, sección de K-Means

👉 Para el fundamento teórico del algoritmo.

Este bloque **marca el límite de K-Means.**

A partir de aquí, todo lo que venga será:

- o cómo **evaluar** lo que ha producido,
- o cómo **romper sus suposiciones** con otros modelos.

► Ejemplo mínimo reproducible · Pipeline completo (escala + clustering)

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
import pandas as pd

df = pd.read_csv("session7_base.csv")
X = df[["feature1", "feature2", "feature3"]].to_numpy()

pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("kmeans", KMeans(n_clusters=3, n_init="auto", random_state=42))
])

labels = pipeline.fit_predict(X)

print("Clusters (primeros 20):", labels[:20])
print("Inercia:", pipeline.named_steps["kmeans"].inertia_)
```

► Si algo no cuadra, revisa...

- ¿Cambian los clusters si cambias `random_state` ?
 - ¿Cambian si quitas el escalado?
 - ¿Los grupos tienen sentido desde el dominio?
-

Interludio · Hoja de ruta mínima del modelador

Antes de evaluar nada, verifica este orden mental:

1. ¿Qué variables definen mi mundo?
(selección de columnas)
2. ¿Están todas en la misma liga?
(escalado / normalización)
3. ¿Cómo mido el parecido entre observaciones?
(distancia implícita o explícita)
4. ¿Cuántos grupos sospecho que tiene sentido proponer?
(K inicial como hipótesis, no como verdad)
5. ¿El resultado es estable si cambio ligeramente las condiciones?
6. ¿Puedo interpretar los grupos en el dominio del problema?

Esto no es una receta.

Es un **orden de preguntas**.

BLOQUE 6 · EVALUAR CLUSTERING CUANDO NO HAY RESPUESTA CORRECTA

Cómo razonar sin etiquetas

6.1 Conexión con lo que ya sabes (anclaje explícito)

Hasta ahora, en todas las sesiones anteriores del curso, evaluar significaba algo muy concreto:

- En la **Sesión 5**, medías error respecto a una variable objetivo.
- En la **Sesión 6**, comparabas modelos usando métricas claras.
- Un número te permitía decidir:
 - si un modelo era mejor,
 - si un cambio había mejorado el resultado.

En los bloques **4 y 5** has hecho algo distinto:

- has aplicado clustering,
- has obtenido grupos,
- **pero no existe ninguna etiqueta real** con la que comparar.

Este bloque existe para responder a una pregunta inevitable:

¿Cómo sé si un clustering “tiene sentido”
cuando nadie me dice cuál es el correcto?

6.2 El error conceptual que hay que evitar desde el principio

El error más común en este punto es intentar reproducir el esquema supervisado:

“Si no tengo etiquetas,
buscaré una métrica que haga de accuracy.”

Esto lleva a:

- confiar ciegamente en un score,
- aceptar resultados incoherentes,
- perder completamente el criterio.

En clustering, esta idea es **conceptualmente incorrecta**:

Si existiera una verdad externa clara,
el problema no sería no supervisado.

Aceptar esto no es resignarse:
es cambiar el tipo de razonamiento.

6.3 Qué significa “evaluar” en clustering (definición correcta)

En clustering, evaluar **no significa verificar una verdad.**

Significa:

analizar si la estructura propuesta por el modelo
es **coherente, estable e interpretable**
dado el espacio y las decisiones tomadas.

Esto introduce un cambio profundo:

- la evaluación deja de ser automática,
 - pasa a ser **razonada**,
 - y tú vuelves a ocupar un papel central.
-

6.4 Dos ideas básicas para razonar un clustering

Aunque no haya etiquetas, sí hay criterios internos que podemos analizar.

Todos los métodos de evaluación no supervisada se apoyan, explícita o implícitamente, en estas dos ideas:

Cohesión

- qué tan parecidos son los puntos **dentro de un mismo cluster**,
- cuánto se “aprietan” alrededor de su centro o región.

Separación

- qué tan distintos están los clusters **entre sí**,
- si realmente ocupan regiones distintas del espacio.

Un clustering razonable suele tener:

- buena cohesión interna,
- buena separación externa.

Esto **no lo hace verdadero**,
pero sí **geométricamente consistente**.

6.5 Inercia: qué mide realmente (y qué no)

En el contexto de K-Means aparece una métrica habitual: la **inercia**.

Conceptualmente, la inercia mide:

- cuán lejos están los puntos de su centroide,
- es decir, cuán compactos son los clusters.

Ideas clave que debes tener claras:

- la inercia **siempre baja** si aumentas K,
- no existe un valor “bueno” universal,
- solo sirve para **comparar modelos sobre el mismo dataset**.

Error típico:

“Este clustering es bueno porque la inercia es baja.”

Síntoma:

- aumentar K indefinidamente y “mejorar” el resultado sin sentido.

👉 La inercia **no evalúa significado**, solo compacidad.

6.6 El método del codo: heurística, no regla

El llamado *método del codo* intenta responder a:

“¿A partir de qué punto añadir más clusters deja de aportar estructura relevante?”

Es una herramienta útil, pero debes entender esto:

- no siempre hay un “codo” claro,
- depende del dataset,
- requiere interpretación humana.

Error típico:

buscar el codo como si fuera una ley matemática.

Síntoma:

- forzar una decisión poco razonable solo porque “ahí parece doblarse la curva”.

Intuición útil · El codo como rendimientos decrecientes

Añadir un cluster más tiene un coste:

- más complejidad,
- más fragmentación,
- más gestión.

Solo tiene sentido si aporta **mucha información nueva**.

El “codo” no es una ley matemática.

Es el punto donde el beneficio de añadir complejidad empieza a decrecer bruscamente.

Más *clusters* no siempre significan mejor comprensión.

6.7 Silhouette score: una ayuda, no un juez

Otra métrica habitual es el **silhouette score**, que combina:

- cohesión (qué tan bien encaja un punto en su cluster),
- separación (qué tan lejos está de los demás).

Aporta más información que la inercia, pero:

- sigue siendo una métrica interna,
- no conoce el dominio,
- no entiende el significado de los grupos.

Error típico:

“Este clustering es mejor porque el silhouette es mayor.”

Síntoma:

- aceptar un resultado que no se puede interpretar, solo porque el número sube.

👉 Las métricas **ayudan a pensar**, no deciden.

Si quieres ver **cómo se definen estas métricas y cuándo se usan**, consulta la sección de evaluación de clustering de scikit-learn, pero siempre con una pregunta previa:

“¿Qué me está diciendo realmente este número?”

6.8 Evaluar también es comprobar estabilidad

Una forma muy potente (y muy poco usada) de evaluar clustering es analizar su **estabilidad**:

- ¿cambia mucho el resultado si:
 - escalas ligeramente los datos?
 - cambias la inicialización?
 - eliminas unos pocos puntos?

Un clustering extremadamente inestable:

- suele ser frágil,
- difícil de interpretar,
- poco útil para decisiones reales.

Este criterio no da un número único,
pero da **información de calidad**.

6.9 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave son:

- no buscar una “accuracy encubierta”,
- usar métricas como **herramientas**, no como jueces,
- analizar cohesión, separación y estabilidad,
- aceptar que la evaluación es **contextual**.

Un buen clustering no es el que tiene mejor score,
sino el que:

| te permite entender mejor tus datos
| y tomar decisiones informadas después.

6.10 Puente explícito hacia el siguiente bloque

Después de evaluar un clustering con K-Means, suele aparecer esta sensación:

| “Esto funciona... pero solo si los datos encajan muy bien.”

Esa intuición es correcta.

En el siguiente bloque veremos qué ocurre cuando:

- los clusters no son esféricos,
- hay ruido,
- o la estructura es más compleja.

Ahí entraremos en **clustering basado en densidad**,
que rompe muchas de las suposiciones de K-Means.

Referencias activadas en este bloque

- scikit-learn — *Clustering evaluation*
👉 Para entender **qué métricas existen y qué miden realmente**.
- Jain, A. K. — *Data clustering: 50 years beyond K-means*
👉 Para una visión crítica de la evaluación en clustering.
- Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, Cap. 14
👉 Para el marco teórico de la evaluación no supervisada.

Este bloque **cierra el ciclo completo de K-Means**:

- definición,
- supuestos,
- y evaluación.

A partir de aquí, el curso avanza de forma natural hacia el clustering basado en densidad

► **Ejemplo mínimo reproducible · Codo + silhouette (comparación, no verdad)**

(Reutiliza  del bloque anterior: tu matriz de features.)

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
import matplotlib.pyplot as plt
```

```
X_scaled = StandardScaler().fit_transform(X)
```

```
Ks = range(2,9)
inertias = []
silhouettes = []
```

```
for k in Ks:
```

```
km = KMeans(n_clusters=k, n_init="auto", random_state=42)
labels = km.fit_predict(X_scaled)
inertias.append(km.inertia_)
silhouettes.append(silhouette_score(X_scaled, labels))
```

```
plt.plot(Ks, inertias)
plt.xlabel("k"); plt.ylabel("Inercia"); plt.show()
```

```
plt.plot(Ks, silhouettes)
plt.xlabel("k"); plt.ylabel("Silhouette"); plt.show()
```

► Si algo no cuadra, revisa...

- ¿Hay realmente un "codo" claro?
- ¿Un silhouette alto produce clusters interpretables?
- ¿Pequeños cambios de k cambian mucho el resultado?

En la hoja de ejercicios de esta sesión trabajarás con un dataset cuya estructura rompe explícitamente las suposiciones de K-Means.

Verás que el algoritmo no "falla":

simplemente intenta forzar los datos

a encajar en un modelo que no les corresponde.

BLOQUE 7 · MÁS ALLÁ DE K-MEANS

Clustering basado en densidad: cuando los grupos no son "redondos"

7.1 Conexión con lo que ya sabes (anclaje explícito)

En los bloques anteriores has recorrido este camino:

- En el bloque **4**, entendiste que el clustering propone estructuras.
- En el bloque **5**, viste que K-Means asume clusters compactos y similares.

- En el bloque 6, aprendiste a evaluar resultados sin etiquetas.

Si has seguido bien el razonamiento, es muy probable que hayas llegado a esta conclusión:

“K-Means funciona...

solo cuando los datos encajan bien en lo que asume.”

Este bloque existe para explorar **qué pasa cuando no encajan**.

7.2 El síntoma que indica que K-Means no es el modelo adecuado

Antes de hablar de otro algoritmo, conviene reconocer **cuándo K-Means deja de ser razonable**.

Síntomas habituales:

- clusters claramente alargados o curvos,
- regiones densas separadas por zonas vacías,
- outliers que “arrastran” centroides,
- resultados muy dependientes del valor de K,
- puntos que no parecen pertenecer a ningún grupo.

Si reconoces estos síntomas, el problema no es:

“No he ajustado bien K-Means”

El problema es:

“K-Means no modela este tipo de estructura”

7.3 Cambiar la pregunta: de centros a densidad

K-Means plantea esta pregunta implícita:

“¿Qué puntos están más cerca de este centro?”

El clustering basado en densidad plantea otra completamente distinta:

“¿Dónde hay regiones del espacio suficientemente pobladas?”

Este cambio de pregunta es profundo:

- ya no importa un centro,
- importa la **concentración local de puntos**,
- el espacio vacío pasa a ser información relevante.

Aquí dejamos de pensar en “grupos alrededor de algo”
y empezamos a pensar en **regiones conectadas**.

7.4 Idea central del clustering por densidad

Conceptualmente, los modelos basados en densidad asumen que:

- un cluster es una región del espacio donde:
 - hay muchos puntos,
 - relativamente cerca entre sí,
- los clusters están separados por regiones menos densas,
- los puntos aislados son **ruido**, no errores.

Esto introduce algo nuevo respecto a K-Means:

No todos los puntos tienen por qué pertenecer a un cluster.

Esta idea es clave y rompe una suposición muy arraigada.

7.5 DBSCAN como modelo representativo (no como receta)

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) es el algoritmo más conocido de esta familia, pero aquí nos interesa como **modelo conceptual**, no como implementación concreta.

Introduce tres nociones fundamentales:

1. **Vecindad**

Un punto “ve” a otros dentro de un cierto radio.

2. **Densidad mínima**

Una región es relevante solo si hay suficientes puntos cerca.

3. **Conectividad**

Los clusters se forman uniendo regiones densas conectadas.

A partir de estas ideas:

- los clusters **emergen**,
- no se imponen desde fuera.

7.6 Qué aporta el clustering por densidad frente a K-Means

Este enfoque permite:

- detectar clusters de forma arbitraria,
- identificar ruido de forma explícita,
- no fijar el número de clusters de antemano,
- respetar mejor la geometría real de los datos.

Por eso se usa con frecuencia en:

- análisis espacial,
- datos geográficos,
- detección de anomalías,
- exploración de sensores.

No es “mejor” en abstracto,

es **adecuado para otro tipo de estructura**.

7.7 Nuevos límites y nuevas decisiones

El clustering por densidad también tiene supuestos y límites:

- asume densidad relativamente uniforme dentro de un cluster,
- es sensible a la escala (otra vez el bloque 2),
- puede fallar en espacios de alta dimensión,
- elegir los parámetros requiere interpretación geométrica.

Error típico:

| pensar que DBSCAN “arregla” lo que K-Means no pudo.

Síntoma:

- exceso de puntos etiquetados como ruido,
- clusters fragmentados sin sentido,
- resultados muy sensibles a pequeños cambios.

7.8 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave son:

- reconocer cuándo los supuestos de K-Means no se cumplen,
- decidir si la estructura esperada es de **densidad**, no de centros,
- aceptar que algunos puntos no pertenezcan a ningún grupo,
- interpretar el ruido como información, no como fallo.

Aquí el modelador deja de preguntar:

| “¿Cuántos clusters quiero?”

y empieza a preguntar:

| “Dónde hay estructura y dónde no”.

7.9 Puente explícito hacia el siguiente bloque

Después de trabajar con clustering por centros y por densidad, aparece un nuevo problema práctico:

“Con muchas variables,
cada vez es más difícil ver y razonar esta estructura.”

Ese problema **no es de clustering**,
es de **representación**.

Eso nos lleva directamente al **bloque 8**:

👉 **Reducción de dimensionalidad: cambiar el espacio para entenderlo mejor**

Referencias activadas en este bloque

- scikit-learn — *DBSCAN clustering*
👉 Para ver **qué parámetros controlan la noción de densidad y vecindad**.
 - Ester et al. — *A Density-Based Algorithm for Discovering Clusters*
👉 Artículo fundacional del enfoque basado en densidad.
 - Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, Cap. 14
👉 Para comparar familias de clustering y sus supuestos.
-

Este bloque **rompe definitivamente la idea de un clustering único y universal**.

A partir de aquí, el alumno ya entiende que:

- los modelos imponen interpretaciones,
- y elegir uno es aceptar sus consecuencias.

► Ejemplo mínimo reproducible · DBSCAN y ruido explícito

```
from sklearn.cluster import DBSCAN
from sklearn.preprocessing import StandardScaler
import numpy as np

X_scaled = StandardScaler().fit_transform(X)
```

```
db = DBSCAN(eps=0.35, min_samples=8)
labels = db.fit_predict(X_scaled)

print("Clusters:", len(set(labels)) - (1 if -1 in labels else 0))
print("Puntos ruido:", np.sum(labels == -1))
print("Etiquetas únicas:", sorted(set(labels)))
```

► **Si algo no cuadra, revisa...**

- ¿Todo es ruido? → revisa `eps` y la escala
- ¿Todo es un cluster? → revisa densidad mínima
- ¿Cambios pequeños lo rompen todo? → estructura frágil

BLOQUE 8 · REDUCCIÓN DE DIMENSIONALIDAD

Cambiar el espacio para poder entenderlo

8.1 Conexión con lo que ya sabes (anclaje explícito)

En los bloques anteriores has trabajado siempre con la misma materia prima:

- un **espacio de características** (2),
- una **noción de distancia** (3),
- modelos que operan sobre ese espacio:
 - clustering por centros (5),
 - clustering por densidad (7).

Si has seguido el razonamiento, es probable que hayas notado una dificultad creciente:

“Cuanto más variables tengo,

| más difícil es entender qué está pasando realmente."

Este problema **no es del algoritmo**.

Es del **espacio en el que estás pensando**.

Este bloque existe para responder a esta pregunta:

| ¿Qué hago cuando el espacio es demasiado complejo
para razonar sobre él directamente?

8.2 El problema real: demasiadas dimensiones dificultan pensar

En datasets reales es habitual encontrar:

- muchas variables,
- variables correlacionadas entre sí,
- información redundante,
- ruido que distorsiona distancias y clusters.

En espacios de alta dimensión ocurre algo importante:

- las distancias pierden poder discriminativo,
- la visualización directa es imposible,
- la interpretación se vuelve frágil.

Aquí aparece una idea clave que conviene fijar:

| A veces, para entender mejor los datos,
no hay que añadir información,
sino **cambiar la forma de representarla**.

8.3 Qué es realmente reducir dimensionalidad (y qué no)

Reducir dimensionalidad **no significa**:

- eliminar variables "porque sobran",
- simplificar sin criterio,
- perder información de forma arbitraria.

Reducir dimensionalidad significa:

construir un nuevo espacio de representación,
de menor dimensión,
que conserve la estructura más relevante de los datos.

Es decir:

- cambias el sistema de coordenadas,
- no el fenómeno que estás observando.

Esta idea conecta directamente con:

- el concepto de espacio visto en el bloque 2,
- y con la noción de estructura introducida en 1.

8.4 Primera gran decisión: por qué quieres reducir dimensiones

Antes de aplicar cualquier técnica, debes tener claro **para qué** reduces dimensiones.

Motivos habituales (y legítimos):

- visualizar datos complejos,
- eliminar redundancia,
- reducir ruido,
- estabilizar clustering,
- facilitar interpretación.

Motivo incorrecto:

"Porque el algoritmo lo pide"

o

“Porque así funciona mejor por defecto”.

En no supervisado, **la reducción de dimensionalidad es una decisión de modelado**, no un paso técnico automático.

8.5 PCA como modelo conceptual (no como truco)

El Análisis de Componentes Principales (PCA) es el ejemplo más clásico de reducción de dimensionalidad, y aquí nos interesa **como modelo**, no como implementación.

Conceptualmente, PCA hace esto:

- busca las direcciones del espacio donde los datos varían más,
- ordena esas direcciones por importancia,
- proyecta los datos sobre las más relevantes.

Cada nueva dimensión (componente principal):

- no coincide con una variable original,
- es una combinación de varias,
- representa una dirección dominante de variación.

Idea clave:

PCA no busca clusters,
busca **estructura de variación**.

8.6 Qué significa “varianza” en este contexto

Aquí conviene aclarar un concepto que suele malinterpretarse.

En PCA, la varianza no es:

- un concepto estadístico abstracto,
- ni un simple número técnico.

Es una idea geométrica:

| mide cuánto "se estiran" los datos
| en una dirección concreta del espacio.

Conservar las direcciones de mayor varianza significa:

- conservar la estructura dominante,
- descartar direcciones con poca información o mucho ruido.

Reducir dimensionalidad **no es perder información al azar**,
es **priorizar qué estructura quieres conservar**.

8.7 Qué se gana (y qué se pierde) al reducir dimensiones

Qué se gana

- espacios más interpretables,
- visualización posible,
- clustering más estable,
- distancias más significativas.

Qué se pierde

- información de detalle,
- variaciones menores,
- a veces interpretabilidad directa de las variables originales.

La pregunta correcta no es:

| "¿pierdo información?"

Sino:

| "¿pierdo información relevante para mi objetivo?"

Esta forma de pensar será esencial más adelante.

8.8 Error típico: usar PCA como preprocesado automático

Uno de los errores más comunes es aplicar PCA como si fuera:

- un paso neutro,
- una mejora garantizada,
- un requisito previo obligatorio.

Síntomas de este error:

- interpretaciones imposibles,
- pérdida de significado semántico,
- clusters difíciles de explicar.

PCA no mejora mágicamente los datos.

Cambia el espacio.

Y cambiar el espacio **siempre tiene consecuencias.**

8.9 Desde el punto de vista del modelador (capa de decisión)

En este bloque, las decisiones clave son:

- decidir si necesitas cambiar el espacio,
- elegir cuánta estructura quieres conservar,
- aceptar la pérdida de interpretabilidad directa,
- usar la reducción como herramienta de comprensión, no como atajo.

Una buena práctica aquí no es:

| “aplico PCA y ya está”,

sino:

comparar lo que ves antes y después
y preguntarte qué ha cambiado realmente.

8.10 Puente explícito hacia lo que viene después

Este bloque cierra la sesión con una idea fundamental:

Hasta ahora, tú has decidido:

- cómo es el espacio,
- cómo se mide la cercanía,
- cómo se reduce la complejidad.

En la siguiente sesión ocurrirá algo nuevo:

- el modelo empezará a **aprender la representación por sí mismo**,
- el espacio dejará de ser fijo,
- la transformación se optimizará automáticamente.

Eso es exactamente lo que hacen las **redes neuronales**.

Gracias a este bloque, ese salto **no será mágico**, sino una evolución natural.

Referencias activadas en este bloque

- scikit-learn — *Dimensionality reduction overview*
👉 Para ver **qué técnicas existen y qué problema aborda cada una**.
- Jolliffe, I. — *Principal Component Analysis*
👉 Referencia clásica para entender PCA como modelo.
- Hastie, Tibshirani, Friedman — *The Elements of Statistical Learning*, secciones sobre reducción de dimensionalidad
👉 Para el marco teórico completo.
- Bishop — *Pattern Recognition and Machine Learning*, capítulos iniciales
👉 Para conectar reducción de dimensionalidad y representación.

► Ejemplo mínimo reproducible · PCA para entender estructura

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

X_scaled = StandardScaler().fit_transform(X)

pca = PCA(n_components=2, random_state=42)
Z = pca.fit_transform(X_scaled)

print("Varianza explicada:", pca.explained_variance_ratio_,
      "Total:", pca.explained_variance_ratio_.sum())
```

```
import matplotlib.pyplot as plt

plt.scatter(Z[:,0], Z[:,1], s=12)
plt.xlabel("PC1"); plt.ylabel("PC2")
plt.show()
```

► Opcional · Clustering sobre espacio reducido

```
from sklearn.cluster import KMeans

km = KMeans(n_clusters=3, n_init="auto", random_state=42)
labels = km.fit_predict(Z)

plt.scatter(Z[:,0], Z[:,1], c=labels, s=12)
plt.show()
```

► Si algo no cuadra, revisa...

- ¿Cuánta varianza estás conservando?
- ¿Pierdes interpretabilidad?
- ¿El clustering mejora o solo "se ve mejor"?

