

REDES NEURONALES

Cuando el diseño manual de modelos deja de escalar

De definir modelos a aprender representaciones

BLOQUE 0 · ENFOQUE GENERAL DE LA SESIÓN

Hasta ahora, en el curso, has aprendido a resolver problemas de datos de una forma consistente:

- entiendes las variables,
- transformas los datos,
- eliges un modelo,
- ajustas parámetros,
- evalúas resultados.

En todas las sesiones anteriores había algo implícito:

Aunque el problema fuera difícil,

alguien (tú) decidía cómo debía pensar el modelo.

En esta sesión ese supuesto empieza a romperse.

Qué va a cambiar hoy (y qué no)

En esta sesión:

- **NO** vas a aprender un framework de deep learning.
- **NO** vas a entrenar redes neuronales “reales” todavía.
- **NO** vas a optimizar arquitecturas ni hiperparámetros.

En esta sesión **SÍ** vas a:

- ejecutar **experimentos controlados** que demuestran límites reales,
- observar cuándo el diseño manual deja de escalar,

- entender por qué aprender representaciones se vuelve inevitable,
- preparar el terreno conceptual para la sesión práctica siguiente.

Esta es una sesión **teórico-experimental**:

cada bloque conceptual se apoya en uno o más laboratorios que **no ilustran la idea, sino que la ponen a prueba**.

Esta sesión no busca habilidad técnica.

Busca **criterio estructural**.

Advertencia al alumno

Esta es una sesión incómoda.

No porque sea difícil,

sino porque **te va a quitar control**:

- no siempre puedes diseñar buenas variables,
- no siempre puedes explicar cada decisión,
- no siempre más intervención humana mejora el modelo.

Eso es deliberado.

BLOQUE 1 · ESTIRANDO LOS MODELOS CLÁSICOS HASTA QUE SE ROMPEN

Durante todo el curso hemos trabajado bajo este supuesto:

Si entiendo bien el problema,
puedo diseñar una representación adecuada y un modelo razonable.

Ese supuesto **no es falso**.

Pero **no siempre es sostenible**.

Funciona bien cuando:

- el número de variables es reducido,
- las relaciones son relativamente simples,

- las interacciones son comprensibles.

Este bloque explora **qué ocurre cuando dejamos de estar en ese mundo**.

Laboratorio 1 · El muro de la linealidad (Crash Test)

Contexto

Se trabaja con un dataset no lineal sencillo (por ejemplo, un patrón tipo "lunas").

Experimento

1. Se entrena un modelo lineal usando solo las variables originales.
2. Se observa que la frontera de decisión es esencialmente recta.
3. Se intenta mejorar el resultado creando variables a mano (transformaciones simples e interacciones).

Qué debes observar con atención

- Cómo cambia la **frontera de decisión** al añadir complejidad manual.
- Qué regiones del espacio **siguen fallando** incluso tras ese esfuerzo.
- Cuántas decisiones humanas son necesarias para lograr mejoras modestas.

Observación clave

El algoritmo no cambia.

Lo que cambia es **la representación diseñada por el humano**.

Pregunta estructural

¿Cuánto trabajo manual es necesario para "forzar"
a un modelo clásico a resolver un problema no lineal sencillo?

Conclusión del bloque

Un modelo clásico puede mejorar mucho...

si el humano consigue construir la representación correcta.

La pregunta importante no es si funciona.

Es:

| ¿qué ocurre cuando ese trabajo manual deja de ser razonable?

BLOQUE 2 · EL LÍMITE HUMANO DEL FEATURE ENGINEERING

En este bloque no se introduce ninguna técnica nueva.

Se demuestra que **lo que ya sabes hacer deja de escalar**, incluso bien aplicado.

Laboratorio 2 · La explosión combinatoria de variables

Contexto

Se trabaja con un dataset de mayor dimensionalidad (por ejemplo, 20 variables).

Experimento

1. Se generan combinaciones automáticas de variables (interacciones y términos polinómicos).
2. El número de columnas crece de forma explosiva.
3. Muchas de las nuevas variables dejan de ser interpretables.

Qué debes observar con atención

- Cómo crece el número de variables sin que crezca la comprensión.
- Cuántas features dejan de tener **significado explicable**.
- La dificultad real de justificar una decisión del modelo.

Observación clave

Aunque el modelo sea técnicamente correcto:

- el humano ya no puede explicar qué representa cada variable,
 - no puede depurar errores con criterio,
 - no puede justificar decisiones del sistema.
-

Conclusión del bloque

El *feature engineering* colapsa cuando:

| el número de decisiones humanas necesarias
| crece más rápido que la capacidad humana para justificarlas.

No es un problema de talento.

Es un problema de **escala cognitiva**.

BLOQUE 3 · CUANDO CAMBIAR EL MODELO YA NO BASTA

Hasta ahora el esquema era siempre el mismo:

| El humano decide qué mirar
| y el modelo aprende sobre eso.

El bloqueo aparece cuando:

- no sabes qué variables crear,
- no sabes qué combinaciones probar,
- no sabes qué ignorar.

Entonces el problema ya no es:

| "¿Qué modelo uso?"

Sino:

| "¿Quién decide la representación del problema?"

En los laboratorios anteriores has visto que,
cuando intentas intervenir más, **rompes más cosas**.

El cambio de rol

Aquí aparece una idea distinta:

| ¿Y si el sistema no aprendiera solo parámetros,

| sino **la forma misma de representar el problema?**

Aceptar esta idea implica:

- renunciar a diseñar cada variable,
- aceptar representaciones internas no interpretables,
- definir solo **qué significa equivocarse**.

El humano deja de diseñar la representación
y pasa a **definir el criterio de error**.

BLOQUE 4 · LA UNIDAD MÍNIMA INEVITABLE

Si el sistema debe aprender representaciones guiado solo por el error,
entonces necesita cumplir unas condiciones mínimas:

- combinar información de varias entradas,
 - ser ajustable de forma continua,
 - introducir no linealidad,
 - poder componerse en estructuras más grandes.
-

Inevitabilidad estructural

Cualquier sistema que:

- solo combine entradas de forma lineal,
- aunque tenga muchas capas,

sigue siendo, en el fondo, **un sistema lineal**.

Por tanto:

| la no linealidad no es un detalle técnico,
| es una **condición de posibilidad**.

La unidad mínima

Después de eliminar todo lo que no sirve, queda una estructura mínima:

- pesos ajustables,
- un término de desplazamiento (*bias*),
- una transformación no lineal.

Esta unidad no es una elección elegante.

Es **lo mínimo que no rompe el aprendizaje**.

BLOQUE 5 · CUANDO UNA SOLA TRANSFORMACIÓN YA NO BASTA

Incluso con la unidad mínima correcta,
una sola transformación no basta en problemas complejos.

Laboratorio visual · Profundidad y abstracción

Se utiliza una herramienta interactiva para observar cómo:

- una sola capa no logra separar patrones complejos,
- añadir una capa oculta permite “doblar” el espacio,
- aumentar profundidad introduce abstracción progresiva.

Qué debes observar con atención

- La diferencia entre “más complejidad” y **mejor organización**.
- Cómo aparecen representaciones intermedias reutilizables.

Observación clave

La profundidad no añade potencia por gusto.

Permite:

- repartir la complejidad,
 - construir representaciones intermedias,
 - aprender jerarquías.
-

BLOQUE 6 · CUANDO TODO DEPENDE DE TODO

En sistemas profundos ocurre algo nuevo:

- cada capa afecta a las siguientes,
- ningún ajuste es local,
- ninguna parte puede entenderse de forma aislada.

Esto no es una afirmación teórica.

Lo has comprobado cuando, al intentar mejorar un caso concreto, el rendimiento global empeoraba.

Consecuencia estructural

Si no puedes ajustar partes por separado, solo queda una guía posible:

| ¿Esto reduce el error global o no?

El aprendizaje se convierte en:

- global,
- iterativo,
- guiado exclusivamente por la señal de error.

El control humano se desplaza:

de diseñar el proceso interno

a **definir correctamente el criterio de error.**

BLOQUE 7 · EL CONTRATO PROFESIONAL

Después de todo esto, es tentador pensar:

| “Si las redes neuronales pueden aprender representaciones complejas, entonces son la solución general”.

Esa conclusión es falsa.

Las redes neuronales **no sustituyen** a los modelos clásicos.
Solo se justifican cuando el enfoque anterior deja de ser viable.

El intercambio real

Aceptar redes neuronales implica aceptar un contrato:

- ganas capacidad y escalabilidad,
- pierdes interpretabilidad y control explícito,
- aumentas coste computacional y riesgo de sobreajuste.

Esto no es un defecto.

Es el **precio estructural** de delegar la representación.

Cierre de la sesión

Recorrido completo:

- el diseño manual deja de escalar,
- el *feature engineering* colapsa,
- aparece la necesidad de aprender representaciones,
- surge una unidad mínima inevitable,
- la profundidad se vuelve necesaria,
- el aprendizaje global se impone,
- el criterio profesional se vuelve central.

Las redes neuronales **no entran por moda**.

Entran **cuando todo lo anterior deja de funcionar**.

Ese es el único lugar donde deben estar.